
电 子 科 技 大 学

学 术 学 位 研 究 生 学 位 论 文 开 题 报 告 表

攻读学位级别： ☐ 博士 ☒ 硕士

学 科 专 业： 计算机科学与技术

学 院： 数学科学学院

学 号： 201721100222

姓 名： 何 佳 美

论 文 题 目： 基于生成对抗网络的电力设备

图像扩充模型及算法研究

指 导 教 师： 李毅超 教授

填 表 日 期： 2018 年 11 月 30 日

电子科技大学研究生院

一、学位论文研究内容

课题类型	<input type="checkbox"/> 基础研究 <input checked="" type="checkbox"/> 应用基础研究 <input type="checkbox"/> 应用研究
课题来源	<input type="checkbox"/> 纵向 <input checked="" type="checkbox"/> 横向 <input type="checkbox"/> 自拟
学位论文研究内容	<p>学位论文的研究目标、研究内容及拟解决的关键性问题</p> <p>1、研究目标：</p> <p>本文针对电力设备图像（X 射线、红外图像等）数据集不足的问题，利用生成对抗网络（GAN）的思想及其相关算法，建立并实现基于生成对抗网络的电力设备图像扩充模型。</p> <p>该模型针对应用在电力设备缺陷检测模型中的图像数据集（原始样本），生成符合原始样本分布的新数据（人工样本），即生成与原始图像类似的电力设备图像。利用生成的人工样本对原始样本进行扩充，使得扩充后的数据集（最终数据集）能够满足缺陷检测模型的训练要求。利用最终数据集对缺陷检测模型进行训练，使得缺陷检测模型的准确率至少提高 2%。</p> <p>2、研究内容：</p> <p>（1）原始样本预处理</p> <p>由于图像扩充模型需要大量的数据集对其进行训练，才能够使得扩充模型具有很好的图像生成能力。而现有的原始样本不能满足图像扩充模型的训练。因此，需要利用常用的数据增强方法，如裁剪、缩放、彩色变换等，对原始样本进行数据扩充。通过对常用的数据增强方法进行研究，查看不同数据增强方法对原始样本的处理效果，筛选出适合于本课题的数据增强方法，对原始样本进行数据增强，最终形成图像扩充模型的训练数据集。</p> <p>由于原始样本的格式、尺寸等不统一不能满足图像扩充模型的输入要求，导致图像扩充模型的训练无法进行，因此，需要对原始样本的格式、尺寸等进行处理。</p> <p>（2）图像扩充模型的构建及实现</p> <p>生成对抗网络模型（GAN）包含两个模型，一个判别模型和一个生成模型。图像扩充模型是基于生成对抗网络的，因此，图像扩充模型中也包含生成模型和判别模型。研究经典的生成对抗网络模型及算法，以及后续衍生出来的其他用于图像生成的生成对抗网络模型及算法，包括 DCGAN、CycleGAN 等。通过对各个模型的网络结构、参数等进行深入的研究，分析其各自的优缺点及使用场景。从中选出几种 GAN 模型对其进行复现，查看生成图像的效果。经过理论的综合分析以及实验的验证比较，选出实用性强以及生成图像质量好的算法作为图像扩充模型的基础算法，构建并实现基于生成对抗网络的电力设备图像扩充模型的初始模型。</p> <p>（3）图像扩充模型的训练及优化</p> <p>对生成对抗网络的训练策略进行研究，选用合适的训练策略，利用训练数据集对初始模型进行训练。对现有的优化器进行研究，最终选出适用图像扩充模型的优化器，实现对模型中参数的优化。同时对图像扩充模型生成的人工样本进行分析，针对人工</p>

	<p>样本图像的质量及训练中出现的问题，调整现有的生成对抗网络的优化方法。根据训练中出现的具体问题，选出适用于本模型的优化方法，对图像扩充模型进行优化改进。</p> <p>3、拟解决的关键性问题：</p> <p>（1）图像扩充模型的构建</p> <p>通过对现有的生成对抗网络模型的研究，并且选出几种生成对抗网络模型对其进行复现。经过理论的分析论证和实验的验证比较，选出实用性强且生成图像质量较好的的算法作为基础算法，以这个基础算法为核心构建初始模型。并对模型中的权重等有关参数进行初始化，选用合适的损失函数及激活函数等，构建基于生成对抗网络的电力设备图像扩充模型的初始模型。</p> <p>（2）图像扩充模型的训练及优化</p> <p>在初始模型上，通过对现有的训练策略研究，选用合适的训练策略，用训练数据集进行训练。通过对现有的优化器的研究，选出适用的优化器实现参数的自动更新。针对训练过程中出现的问题以及人工样本图像的质量，研究现有的优化方法，选出合适优化方法并进行改进，对图像扩充模型进行优化改进。</p>
--	----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------

二、学位论文研究依据

学位论文的选题依据和研究意义，国内外研究现状和发展态势，主要参考文献，以及已有的工作积累和研究成果。（2000 字）

1、选题依据

随着人工智能的兴起与发展，人工智能已经逐渐应用于各个领域。2017 年国务院印发了《新一代人工智能发展规划的通知》，将人工智能的发展作为基本国家战略。对于人工智能在我国各个领域中的发展进行了规划和指导，针对各个领域提出了明确的规划和指导路线。同时针对我国人工智能发展的迫切需求和薄弱环节，设立了一批新一代人工智能重大科技项目。同时指出要大力发展各个行业中的人工智能企业。

电力设备状态检测、监测当然也不例外。目前电力设备缺陷检测主要采用无损检测技术。无损检测技术是指基于不影响或者危害被检测对象具体功能的条件下，通过射线、红外线等技术对设备、零件、材料等实施物理、化学、缺陷的检测技术^[1]。无损检测技术主要有超声检测、射线检测^[2]、声发射检测、红外检测等。利用 X 射线检测、红外检测等无损检测技术对电力设备进行图像采集。专业的技术检测人员将采集回来的图像进行分析处理，从而实现对电力设备中的缺陷进行判别。但是这个检测过程需要耗费很多的时间，并且采集回来的图像远多于专业技术检测人员的数量，因此要识别出采集回来的电力设备图像中的所有缺陷需要花很长一段时间。所以，非常需要利用深度学习实现电力设备缺陷的智能检测。

根据国家人工智能的总体规划，智能电网大数据平台的建设正在快速推进，其中核心部分就包括利用深度学习实现电力设备缺陷智能检测。要利用深度学习中的算法实现电力设备缺陷智能检测模型需要大量的数据集。即要实现准确率高的缺陷智能检测模型需要大量的数据集对模型进行训练、验证、优化，才能够使得模型具有较好的泛化能力和准确率，才能够训练出适用于电力设备缺陷智能检测的模型。

但是，对电力设备的检测都是定时进行维修检测，并且相隔时间期限较长。某些电力设备所处的位置偏僻，采集一次需要耗费大量的人力和物力。而对于新修建的电力设备在初次检测完成无缺陷后很长一段时间都不会进行再次检测。由于以上原因，导致现有的电力设备图像数据集较少，不能够满足电力设备缺陷智能检测模型的训练。使得构建的电力设备缺陷智能检测模型的效果不好，从而导致智能电网大数据平台的建设无法继续推进。因此，目前非常需要一种扩充数据集的方法来解决电力设备图像数据集过少的问题。

2、研究意义

随着人工智能的兴起与发展，人工智能被应用到各个领域。国家对于人工智能在各个领域的发展进行了规划和指导。根据国家人工智能总体规划，四川赛康智能科技股份有限公司提出了智能电网大数据平台。而该平台的建设需要用到大量深度学习的有关模型及算法，其中核心部分就包括电力设备缺陷智能检测模型，对于模型的训练需要大量的数据集。现有的电力设备图像数据集不足以支持缺陷智能检测模型的训练。因此，非常需要一种扩充数据集的方法来解决电力设备图像数据集过少的问题。

本课题在于利用生成式对抗网络的思想及其相关算法，针对现有的电力设备图像数据集不足的问题，构建电力设备图像扩充模型生成大量与原图像（原始样本）相似的电力设备图

像（人工样本）。弥补目前电力设备图像数据集不足的问题。将最终数据集用于电力设备缺陷检测模型的训练，从而提高模型的准确率。从而使得电力设备缺陷检测能够高效快速的进行。继而能够推进智能电网大数据平台的建设，促进电力设备人工智能化的发展。对于我国智能电网的建设以及电力设备状态检测具有重大意义。

3、国内外研究现状和发展态势

3.1 电力设备检测研究现状

随着计算机技术、数字化技术和图像识别技术的发展，无损检测技术被广泛的应用于电力设备检测中。无损检测技术是在不破坏检测对象的前提下进行对于检测对象的检测，检测内容是评价检测物体内部或者表面物理和机械性及各类缺陷和其他的技术参数^[3]。同时，无损检测能够满足电力行业的高安全性和稳定性的要求，这使得其成为保证电力设备处于良好运行状态的技术之一。

目前而言，无损检测技术主要有超声检测、射线检测、声发射检测、红外检测、渗透检测、磁粉检测、涡流检测这几种，在电力设备检测中都有所涉及，但就其应用广泛性和发展前景而言，尤以超声检测、射线检测、声发射检测最为突出^[4]。

由于无损检测技术在我国的应用时间还不是很长，并且电力设备检测的周期较长，使得目前采集的图像数据量较少，无法满足对于电力设备缺陷智能检测模型的训练。就目前而言，并未有对于电力设备图像数据集进行增强的相关研究。而在其他应用领域的基于生成对抗网络的图像生成技术发展得如火如荼。

3.2 生成对抗网络研究现状

机器学习方法包括两类：生成方法和判别方法，最后得到的模型称之为生成式模型（generative model）和判别式模型（discriminative model）^[5]。生成方法是通过对样本数据进行学习从而得到基于样本与标签的联合概率分布。从而使得训练好的模型生成的新数据是与原始样本分布相符的。生成模型既可以是有监督的学习也可以是无监督的学习。其中无监督的学习是通过学习真实数据的本质特征，从而让模型掌握样本数据的分布特征，最后生成与原始数据高度相似的新数据。由于生成模型的参数比训练数据的量小好几个数量级，因此模型能够发现并有效内化数据的本质。生成式模型在无监督深度学习方面占据主要位置，在没有目标标签的情况下能自主的捕捉预测出对应数据的高阶相关性。深度生成模型可以通过从网络中采样来有效生成样本，近两年来流行的生成式模型主要分为三种方法：生成对抗网络（GAN）^[6]，变分自动编码模型（VAE）^{[7][8]}，自回归模型（Auto-regressive）^[9]。其中，本文主要研究的是生成对抗网络（GAN）。

生成对抗网络（Generative Adversarial Networks, GANs）是由 Goodfellow 等人在 2014 年提出的一种非监督式的学习方法^[6]。GAN 思想来源于博弈论，是由两个神经网络组成，分别包含一个生成模型（G）和一个判别模型（D）。GANs 让生成器和判别器以相互博弈的方式进行学习：生成模型学习样本的真实分布，从某种噪声分布中随机采样作为输入，生成于真实样本非常相似的人工样本。而判别模型则对输入的真实样本或人工样本进行判别，尽可能的将真实样本和人工样本区分出来。从中可以看出，生成模型的功能就是尽可能生成与真实数据类似的人工数据来欺骗判别器，而判别器则是尽力的从这些样本中将真实样本和人

工样本区分开来。训练的过程中，是对两个模型的交替训练。两个神经网络相互对抗，在对抗的过程中不断调整自身的参数，双方的能力因此都得到上升。最终，产生了一个“造假”能力很强的生成模型，可以生成以假乱真的人工样本。GANs 目前主要的应用领域在图像、视频、文本生成方面，如通过 GANs 来生成以假乱真的图片^[10]；预测视频的下一帧是什么^[11]；在自然语言处理领域用以生成文本序列^[12]。

由于 GAN 的学习模式太过于自由了，使得 GAN 的训练过程和训练结果很多时候都不太可控。为了稳定 GAN，从启发式的、模型改进和理论分析的角度上后来都提出了许多训练技巧和改进方法。在基础的 GANs 上，根据实际的需求以及原始 GAN 的不足，衍生出了许多 GANs 的变种。

由于 GAN 不需要事先建模的方法太过自由，当数据集中图像的尺寸较大且包含复杂的内容时，使用简单的 GAN 很难控制生成人工样本的效果，对于样本的输出无法控制。Mehdi Mirza 等人于 2014 年提出的条件对抗网络（Conditional Generative Adversarial Nets, CGAN）^[13]，通过在生成模型和判别模型中都引入额外的条件变量 y ，而这个条件变量 y 可以辅助引导人工样本的生成，条件变量 y 可以是类别标签、对图像修复有帮助的部分辅助数据等等。此时就是将 GAN 从纯无监督向有监督学习进行改进。从而改进了原始 GANs 对于人工样本输出类别无法指定的问题。

针对 GAN 训练过程中可能出现的不稳定的问题，Alec Radford 等人于 2015 年提出的深度卷积对抗网络（Deep Convolutional Generative Adversarial Networks, DCGAN）^[10]，将有监督学习的 CNN[14]和无监督学习的 GAN 相结合，对 GAN 的生成模型和判别模型的架构进行修改，将深度卷积神经网络结构使用到 GAN 中，得到了更稳定的训练过程和更高质量的图像样本。但是该网络架构只是基于对生成模型和判别模型的架构进行不断实验，最终选出一种比较好的网络架构。只是从表面解决了训练不稳定的问题，并没有从原理上解决问题。

Arjovsky 与 Gulrajani 等人用了两篇论文，针对 GANs 存在的训练不稳定，生成样本缺乏多样性等通病，尝试从数学角度分析，并提出了改进后的 Wasserstein GAN 模型^{[15][16]}。解决了 GAN 训练不稳定的问题，不需要再小心的衡量生成模型（G）和判别模型（D）的训练程度，而且最终生成的人工样本具有多样性。生成模型生成的人工样本的质量也较之前有所提高，但实验表明该方法的收敛速度较慢，同一数据集下需要多次训练才能收敛^[17]。

除了上述几种对于 GAN 的衍生，还有其他很多方面的改进。比如，Jun-Yan Zhu 等人于 2017 年提出的循环一致性对抗网络（Cycle-Consistent Adversarial Networks, Cycle GAN）使用一对 GANs 在两个类别的数据之间相互训练，完成了带风格迁移效果的样本生成任务^[18]；Patch GAN 和 Pixel GAN^[19] 结构用于图片到图片的转移，通过输入图片以及带条件的图片，使得生成网络最终能够生成非常接近于条件图片。Patch GAN 和 Pixel GAN 改进网络中的目标函数，生成模型和判别模型的判别方式，将图像分成若干个小块进行判别，最终给出平均结果，相较于整张图像的判别更易于收敛^[20]。

3.3 生成对抗网络应用现状

GANs 是深度学习在无监督学习上一个新的创举。目前 GAN 可能在以下应用领域发挥作用。如由卫星照片生成地图（地图绘制）；由黑白图像生成彩色图像（老旧照片上色）；由手绘图片生成真实照片（嫌犯画像绘制）；由低分辨率图片生成高分辨率图片（超分辨率重

建)^[21]；医学图像合成、医学图像分割等^[22]。但由于 GANs 诞生的时间不长，其架构等目前都尚处于研究阶段，想在实际的应用场景中运用 GANs 技术仍需时日。

但是，随着 GANs 研究的深入，合成的人工样本图像也越来越真实。近年来也逐渐出现了将 GANs 用于生成人工样本来扩充数据集的研究。Wang 等人对利用 GANs 提升监督学习准确率的想法进行了分析，并得出肯定结论^[23]；Shrivastava 等人在 MPIIGaze 数据集上，利用 GANs 对已有的人工样本再进行优化，提高了眼球角度预测和手势识别任务的准确率^[24]。Madani 等人使用 GAN 来生成胸部 X 射线图像以增强数据集^[25]，用于训练卷积神经网络，进行心血管异常的分类。与传统数据增强方法相比，用 GAN 进行增强能达到更高的分类准确度；Galbusera 等人也基于所需解剖结构轮廓的简单图像，利用 GAN 生成腰椎的平面 X 射线图像^[26]。

此外，Lucic 等人对原始 GANs 和众多 GANs 的衍生模型在统一标准下进行了评价，认为原始 GANs 相比于当前多数衍生模型，仍具有优秀的生成能力^[27]。从上述将 GANs 生成的人工样本用于扩充数据集的研究中，可以看到 GANs 对于生成人工样本用于扩充数据集，利用扩充后的数据集对于提高各种模型的准确率用巨大的潜力。

参考文献

- [1] 冯耀庆. 954: 电力设备无损检测技术研究[J]. 科学与财富, 2018, (27): 126.
- [2] 王进, 杨迎春, 吴章勤, 等. 电网设备无损检测新技术应用[J]. 云南电力学术, 2013, 41(5): 75-77, 86.
- [3] 苑美实, 骆令海. 无损检测技术在电力系统中的应用[J]. 科技创新, 2018, (21): 159-160.
- [4] 孙言蓓. 电力设备无损检测技术研究[J]. 中国高新技术企业, 2015, (18): 29-30.
- [5] Wang L. Joint Probability Distribution[J]. 2013, 52(4): 1063-1063.
- [6] Goodfellow I J, Pougetabadie J, Mirza M, et al. Generative Adversarial Networks[J]. Advances in Neural Information Processing Systems, 2014, 3: 2672-2680.
- [7] Kingma D P, Welling M. Auto-Encoding Variational Bayes[J]. 2014.
- [8] Rezende D J, Mohamed S, Wierstra D. Stochastic Backpropagation and Approximate Inference in Deep Generative Models[J]. Eprint Arxiv, 2014: 1278-1286.
- [9] Chan A B, Vasconcelos N. Probabilistic Kernels for the Classification of Auto-Regressive Visual Processes[C]// IEEE Computer Society Conference on Computer Vision and Pattern Recognition. IEEE Computer Society, 2005: 846-851.
- [10] Radford A, Metz L, Chintala S. Unsupervised representation learning with deep convolutional generative adversarial networks[J]. ar Xiv preprint ar Xiv:1511.06434, 2015.
- [11] Mao X, Li Q, Xie H, et al. Least squares generative adversarial networks[C]. 2017 IEEE International Conference on Computer Vision (ICCV). IEEE,

2017:2813–2821.

- [12] Lotter W, Kreiman G, Cox D. Unsupervised learning of visual structure using predictive generative networks[J]. ar Xiv preprint ar Xiv:1511.06380, 2015.
- [13] Mirza M, Osindero S. Conditional generative adversarial nets[J]. ar Xiv preprint ar Xiv:1411.1784, 2014.
- [14] Fukushima K. Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position[J]. Biological Cybernetics, 1980, 36 (4) :193–202.
- [15] Arjovsky M, Chintala S, Bottou L. Wasserstein gan[J]. ar Xiv preprint ar Xiv:1701.07875, 2017.
- [16] Gulrajani I, Ahmed F, Arjovsky M, et al. Improved training of wasserstein gans[C]. Advances in Neural Information Processing Systems. 2017: 5769–5779.
- [17] 曹仰杰, 贾丽丽, 陈永霞, 林楠, 李学相. 生成式对抗网络及其计算机视觉应用研究综述[J]. 中国图象图形学报, 2018, 23(10):1433–1449.
- [18] Zhu J Y, Park T, Isola P, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks[J]. ar Xiv preprint ar Xiv:1703.10593, 2017.
- [19] Isola P, Zhu J Y, Zhou T, et al. Image-to-Image Translation with Conditional Adversarial Networks[J]. 2016.
- [20] 肖旭. 基于深度学习的图像语义分割研究[D]. 南昌航空大学, 2017.
- [21] Miyato T, Koyama M. c GANs with projection discriminator[J]. ar Xiv preprint ar Xiv:1802.05637, 2018.
- [22] 陈锟, 乔沁, 宋志坚. 生成对抗网络在医学图像处理中的应用[J]. 生命科学仪器, 2018, 16(Z1):71–80+91.
- [23] Wang J, Perez L. The effectiveness of data augmentation in image classification using deep learning[R]. Technical report, 2017.
- [24] Shrivastava A, Pfister T, Tuzel O, et al. Learning from simulated and unsupervised images through adversarial training[C]. The IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017, 3(4): 6.
- [25] Madani A, Moradi M, Karargyris A, et al. Chest x-ray generation and data augmentation for cardiovascular abnormality classification[C]. SPIE Medical Imaging, 2018:6.
- [26] Galbusera F, Niemeyer F, Seyfried M, et al. Exploring the Potential of Generative Adversarial Networks for Synthesizing Radiological Images of the Spine to be Used in In Silico Trials. Frontiers in bioengineering and biotechnology. 2018:53.
- [27] Lucic M, Kurach K, Michalski M, et al. Are GANs Created Equal? A Large-Scale Study[J]. ar Xiv preprint ar Xiv:1711.10337, 2017.

三、学位论文研究计划及预期目标

1. 拟采取的主要理论、研究方法、技术路线和实施方案

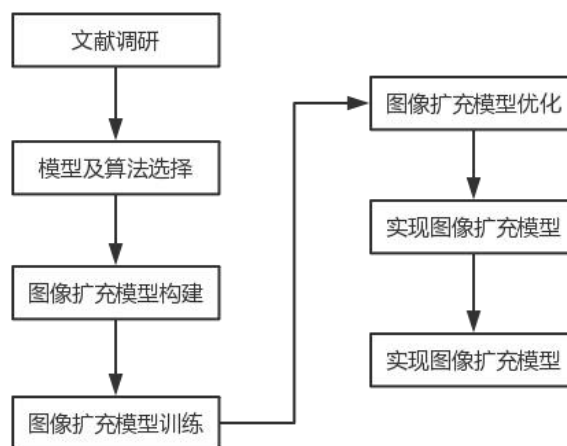
1.1 拟采取的主要理论

- (1) 数据增强
- (2) 生成对抗网络
- (3) 卷积神经网络
- (4) 残差神经网络

1.2 研究方法

- (1) 文献研究法
- (2) 实验法

1.3 技术路线



首先对现有的生成对抗网络模型进行调研并实现经典模型的复现，从经典的生成对抗网络模型中选出适用于本场景且生成图像质量较好的模型和算法，并基于上述选择出的模型和算法构建图像扩充模型。将电力设备图像数据集（原始样本）进行预处理得到训练集，利用训练数据集对图像扩充模型尽心训练。针对训练过程中出现的问题，对图像扩充模型进行优化得到最终模型，对最终模型的效果进行测试和评估。最终实现图像扩充模型。

1.4 实施方案

(1) 对现有的生成对抗网络进行调研，并对几大经典生成对抗网络模型进行深入研究，比较分析这几大经典模型的优缺点、适用环境、生成图像质量等。

(2) 经过上述文献的调研，从中选出几种生成对抗网络模型进行复现，利用网上的数据集，比如 celebA 人脸数据集，对这些模型进行训练，查看生成图像质量的效果，熟悉生成对抗网络模型的构建训练过程。经过上述理论分析以及实验验证，选出适用于本场景且生成图像质量较好的生成对抗网络模型及算法，构建并实现基于生成对抗网络的电力设备图像扩充模型的初始模型，包括生成器和判别器的构建、生成器与判别器目标函数、优化器的选择，参数的初始化等。

(3) 由于电力设备图像数据集不足以支持图像扩充模型的训练，因此，利用传统的数

据增强方法，如裁剪、缩放、彩色变换等，对原始样本进行数据扩充得到训练数据集。并对训练数据集进行尺寸统一、格式统一等预处理操作。

（4）选用较优的训练策略、合适的迭代次数、批次数量等，利用训练数据集对模型进行训练。根据模型的训练效果，有选择的对模型中的学习率、激活函数等进行修改，实现对图像扩充模型的优化。

（5）将图像扩充模型生成的最终数据集用于电力设备缺陷检测模型的训练、验证和测试。将最后测试得到缺陷检测模型的准确率与之前相比较，用以评价该模型。最终实现图像扩充模型。

2. 研究计划可行性，研究条件落实情况，可能存在的问题及解决办法（可续页）

2.1 研究计划可行性

目前，在医学领域已经使用生成对抗网络进行医学影像数据集的生成，以扩充医学影像数据集。而电力设备中 X 射线成像与医学中 X 射线成像原理相同，所以，将生成对抗网络用于电力设备图像数据集的扩充也是可行的。

2.2 研究条件落实情况

目前已有的双 1080T 显卡服务器型号为 DELL T630，开发环境为 TensorFlow1.12，基于 CUDA9.0，使用 Python3.6 作为开发语言，使用四川赛康智能科技有限公司提供的电力设备图像作为数据集。

2.3 可能存在的问题及解决办法

（1）人工样本质量的评估

对于图像扩充模型生成的人工样本质量评估，可以将最终数据集用于缺陷检测模型的训练、验证和测试，查看缺陷检测模型的准确率较使用原始样本是否提高作为评估标准。

（2）人工样本质量不佳

在训练的过程中生成的人工样本质量不佳，可以通过对模型的参数、学习率、网络结构等进行修改优化。

3. 研究计划及预期成果		
研究计划	起止年月	完成内容
	2018. 09-2018. 11	查阅国内外相关文献，对于研究方向有个初步的认识和分析；学习生成对抗网络
	2018. 12-2019. 01	通过文献的调研以及实验验证，选出适用性强以及生成图像质量好的模型、算法
	2019. 02-2019. 05	对电力设备图像数据集进行预处理；基于选出的模型算法构建图像扩充模型的初始模型
	2019. 06-2019. 11	利用训练数据集对图像扩充模型进行训练优化，完成最终模型的测试和评估，实现图像扩充模型
	2019. 12-2020. 03	按照相关要求和规定完成毕业论文的撰写
预期创新点及成果形式	<p>1、学位论文创新点</p> <p>目前，在医学领域已经使用生成对抗网络进行医学影像数据集的生成。但是，尚没有将 GAN 用于电力设备图像扩充的研究，本课题首次将生成对抗网络用于电力设备图像的扩充。</p> <p>2、成果形式</p> <p>(1) 基于生成对抗网络的电力设备图像扩充模型及算法的源代码</p> <p>(2) 一篇《基于生成对抗网络的电力设备图像扩充模型及算法研究》学位论文</p> <p>(3) 一篇《基于生成对抗网络的电力设备图像增强》学术论文</p> <p>(4) 一个“基于生成对抗网络的电力设备图像增强方法”的专利</p>	

四、开题报告审查意见

1. 导师对学位论文选题和论文计划可行性意见，是否同意开题：

导师（组）签字：

年 月 日

2. 开题报告考评组意见

开题日期		开题地点	
考评专家			
考评成绩	合格____票	基本合格____票	不合格____票
结 论	<input type="checkbox"/> 通过 <input type="checkbox"/> 原则通过 <input type="checkbox"/> 不通过 通 过： 表决票均为合格 原则通过： 表决票中有 1 票为基本合格或不合格，其余为合格和基本合格 不 通 过： 表决票中有 2 票及以上为不合格		

考评组对学位论文的选题、研究计划及方案实施的可行性的意见和建议:

考评组签名:

年 月 日

3. 学院意见:

负责人签名:

年 月 日

起止时间	负责人	任务模块	人员配置	成果形式
2018.12.10-2018.12.23	何佳美	GAN 深入研究及模型复现	研一 1 人	分析报告及源代码
2018.12.24-2018.01.06	何佳美	DCGAN 深入研究及模型复现	研一 1 人	分析报告及源代码
2018.01.07-2018.01.20	何佳美	WGAN 深入研究及模型复现	研一 1 人	分析报告及源代码
2019.01.21-2019.01.31	何佳美	整合分析报告选出模型及算法	研一 1 人	分析报告
2019.02.01-2019.02.28	何佳美	原始样本预处理	研一 2 人	训练数据集
2019.03.01-2019.03.15	何佳美	构建初始的图像扩充模型		初始模型
2019.03.15-2019.04.15	何佳美	训练图像扩充模型	研一 1 人	源代码
2019.04.16-2019.05.31	何佳美	优化图像扩充模型	研一 2 人	最终模型及源代码
2019.06.01-2019.06.24	何佳美	模型评估和测试	研一 2 人	测试报告